

**Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών  
Υπολογιστών**

Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης



**Νευρωνικά Δίκτυα – Βαθιά Μάθηση**  
**Εργασία 3**

Τζίνα Θεοδώρα (ΑΕΜ: 10715)

# Περιεχόμενα

|          |                                                          |           |
|----------|----------------------------------------------------------|-----------|
| <b>1</b> | <b>Εισαγωγή</b>                                          | <b>3</b>  |
| <b>2</b> | <b>Μέρος Α: Autoencoder – Simple Reconstruction</b>      | <b>3</b>  |
| 2.1      | Model 1: Simple Dense Autoencoder                        | 3         |
| 2.2      | Model 2: Deeper Dense Autoencoder                        | 4         |
| 2.3      | Model 3: Larger bottleneck Autoencoder                   | 5         |
| 2.4      | Model 4: Autoencoder with extra metrics                  | 6         |
| 2.5      | Model 5: Convolutional Autoencoder                       | 7         |
| 2.6      | Model 6: PCA Reconstruction                              | 8         |
| 2.7      | CNN Classifier                                           | 9         |
| <b>3</b> | <b>Μέρος Β: Autoencoder – Next Digit Reconstruction</b>  | <b>10</b> |
| 3.1      | Model 1: Dense Next Digit Autoencoder                    | 10        |
| 3.2      | Model 2: Convolutional Next Digit Autoencoder            | 11        |
| 3.3      | Model 3: Advanced Convolutional Next Digit Autoencoder   | 12        |
| 3.4      | Model 4: U-Net Style Next Digit Autoencoder              | 14        |
| <b>4</b> | <b>Μέρος Γ: Autoencoder – Digit Adder Reconstruction</b> | <b>15</b> |
| 4.1      | Model 1: Dense Digit Adder Autoencoder                   | 16        |
| 4.2      | Model 2: Deeper Dense Digit Adder Autoencoder            | 17        |
| 4.3      | Model 3: Convolutional Digit Adder Autoencoder           | 19        |
| 4.4      | Model 4: U-Net Style Digit Adder Autoencoder             | 20        |

# 1 Εισαγωγή

Στην παρούσα εργασία καλούμαστε να υλοποιήσουμε και να μελετήσουμε τη συμπεριφορά διάφορων αρχιτεκτονικών **Autoencoders** (Αυτόματων Κωδικοποιητών), καθώς και να συγκρίνουμε την απόδοσή τους στην ανακατασκευή εικόνων με τη μέθοδο ανάλυσης κυρίων συνιστωσών (**PCA**). Επιπλέον, εξετάζουμε την ποιότητα των ανακατασκευασμένων εικόνων χρησιμοποιώντας τις ως είσοδο σε έναν ταξινομητή (CNN classifier) για το πρόβλημα αναγνώρισης ψηφίων.

Για τις ανάγκες της άσκησης χρησιμοποιήθηκε το **MNIST** dataset, μέσω της βιβλιοθήκης Keras της Tensorflow, το οποίο αποτελείται από χειρόγραφα ψηφία (0-9). Το σύνολο δεδομένων περιλαμβάνει 60.000 εικόνες εκπαίδευσης και 10.000 εικόνες ελέγχου, διαστάσεων 28x28 pixels.

Στόχος της εργασίας είναι η εύρεση της βέλτιστης αρχιτεκτονικής που ελαχιστοποιεί το σφάλμα ανακατασκευής (Mean Squared Error - MSE) και μεγιστοποιεί την οπτική πιστότητα των παραγόμενων εικόνων.

Όλες οι βοηθητικές συναρτήσεις εισαγωγής δεδομένων, απεικόνισης αποτελεσμάτων κλπ. βρίσκονται στο αρχείο *dataProcessing.py*.

## 2 Μέρος A: Autoencoder – Simple Reconstruction

Στο πρώτο μέρος της εργασίας, υλοποιήθηκαν και αξιολογήθηκαν 5 διαφορετικά μοντέλα Autoencoders, ξεκινώντας από απλά πλήρως συνδεδεμένα (Dense) δίκτυα και καταλήγοντας σε ένα πιο σύνθετο συνελικτικό (Convolutional) μοντέλο. Η εκπαίδευση έγινε χρησιμοποιώντας τον αλγόριθμο βελτιστοποίησης Adam και ως συνάρτηση κόστους το Mean Squared Error (MSE).

Η υλοποίηση του μέρους A βρίσκεται στο αρχείο *Autoencoder\_A.ipynb*.

### 2.1 Model 1: Simple Dense Autoencoder

Το πρώτο μοντέλο αποτελεί έναν βασικό autoencoder με μικρή διάσταση στον λανθάνοντα χώρο (encoding dimension = 32). Χρησιμοποιούνται μόνο λίγα Dense layers χωρίς να υπάρχει περίπλοκη αρχιτεκτονική και το μοντέλο εκπαιδεύεται για 50 εποχές. Τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Training Time: 46.5 seconds
- Final Validation Loss: 0.008981
- Test MSE: 0.008539




Figure 1: Καμπύλες σφάλματος training και validation




Figure 2: Αναπαράσταση ψηφίων εισόδου και ανακατασκευής

Παρατηρούμε ότι το μοντέλο εκπαιδεύεται γρήγορα, δίνοντας αρκετά ικανοποιητικές ανακατασκευές. Λόγω της απλής δομής και της ισχυρής συμπίεσης (32 features), παρατηρείται κάποια απώλεια λεπτομέρειας (θόλωμα), το οποίο προδίδεται και από την τιμή του MSE.

## 2.2 Model 2: Deeper Dense Autoencoder

Στο δεύτερο μοντέλο αυξάνεται το βάθος του δικτύου και η διάσταση του λανθάνοντος χώρου (encoding dim = 64), προσθέτοντας επιπλέον Dense layers. Εκπαιδεύουμε και πάλι για 50 εποχές και τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Training Time: 141.01 seconds
- Final Validation Loss: 0.005913
- Test MSE: 0.005632




Figure 3: Καμπύλες σφάλματος training και validation




Figure 4: Αναπαράσταση ψηφίων εισόδου και ανακατασκευής

Παρατηρούμε ότι η αύξηση της χωρητικότητας του δικτύου οδήγησε σε μείωση του σφάλματος ανακατασκευής (MSE), καθώς το δίκτυο μπορεί να κωδικοποιήσει περισσότερη πληροφορία.

### 2.3 Model 3: Larger bottleneck Autoencoder

Το τρίτο μοντέλο διατηρεί όμοια αρχιτεκτονική μεταβάλλοντας μόνο τη διάσταση του λανθάνοντος χώρου (encoding dim = 128). Η εκπαίδευση γίνεται για 50 εποχές και τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Training Time: 139.5 seconds
- Final Validation Loss: 0.003661
- Test MSE: 0.003495




Figure 5: Καμπύλες σφάλματος training και validation




Figure 6: Αναπαράσταση ψηφίων εισόδου και ανακατασκευής

Παρατηρούμε ότι η ισορροπία μεταξύ βάθους μοντέλου και συμπίεσης των δεδομένων, επιτρέπουν την ιεραρχική εξαγωγή χαρακτηριστικών και συμβάλλουν στην καλύτερη αναπαράσταση των ψηφίων, μειώνοντας όλο και περισσότερο το MSE.

## 2.4 Model 4: Autoencoder with extra metrics

Το μοντέλο αυτό διατηρεί ακριβώς πανομοιότυπη αρχιτεκτονική χρησιμοποιώντας όμως κάποιες νέες μετρικές αξιολόγησης:

1. **PSNR** (Peak Signal-to-Noise Ratio): Εκφράζει τον λόγο της μέγιστης δυνατής ισχύος της εικόνας προς την ισχύ του θορύβου (σφάλμα ανακατασκευής) και μετριέται σε Decibels (dB). Όσο υψηλότερη είναι η τιμή, τόσο καλύτερη η ποιότητα της ανακατασκευασμένης εικόνας.
2. **SSIM** (Structural Similarity Index Measure): Σε αντίθεση με το MSE που κοιτάζει μεμονωμένα pixels, το SSIM εξετάζει τη δομική ομοιότητα, τη φωτεινότητα και την αντίθεση. Παίρνει τιμές στο διάστημα  $[-1, 1]$ , όπου το 1 υποδηλώνει απόλυτη ταύτιση με την πρωτότυπη εικόνα.

Εκπαιδεύουμε ξανά για 50 εποχές και τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Training Time: 210.43 seconds
- Final Validation Loss: 0.003616
- Final Validation PSNR: 25.728479
- Final Validation SSIM: 0.960668
- Test MSE: 0.003453




Figure 7: Καμπύλες σφάλματος training και validation




Figure 8: Αναπαράσταση ψηφίων εισόδου και ανακατασκευής

Παρατηρούμε ότι το MSE παραμένει χαμηλά χωρίς κάποια επιπλέον βελτίωση, ωστόσο οι τιμές PSNR, SSIM επιβεβαιώνουν την εγκυρότητα του συγκεκριμένου μοντέλου αφού προδίδουν την απουσία περιττού θορύβου.

## 2.5 Model 5: Convolutional Autoencoder

Σε αυτό το πείραμα, αλλάζει τελείως η αρχιτεκτονική καθώς δημιουργείται ένα νέο συνελικτικό μοντέλο. Σε αντίθεση με τα Dense layers που ισοπεδώνουν την εικόνα, καταστρέφοντας τη δισδιάστατη δομή της, τα Conv2D layers, την επεξεργάζονται ως πλέγμα επιτρέποντας τον εντοπισμό τοπικών χαρακτηριστικών. Γίνεται χρήση των BatchNormalization layers καθώς αναμένεται υψηλότερος χρόνος εκπαίδευσης άρα και μεγαλύτερη

ανάγκη διατήρηση σταθερότητας. Εκπαιδεύουμε για 30 εποχές και τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Training Time: 2705.37 seconds
- Final Validation Loss: 0.002515
- Final Validation PSNR: 28.198368
- Final Validation SSIM: 0.971523
- Test MSE: 0.002452




Figure 9: Καμπύλες σφάλματος training και validation




Figure 10: Αναπαράσταση ψηφίων εισόδου και ανακατασκευής

Παρατηρούμε ότι πράγματι ο χρόνος εκπαίδευσης αυξήθηκε εκθετικά, ωστόσο παρά τις λιγότερες εποχές εκπαίδευσης το συνολικό μοντέλο οδήγησε στην βέλτιστη έως τώρα απόδοση, πλησιάζοντας την τέλεια ανακατασκευή.

## 2.6 Model 6: PCA Reconstruction

Σε αυτή τη φάση εξετάζεται η ανακατασκευή μέσω του έτοιμου μαθηματικού γραμμικού μοντέλου, διατηρώντας το 95% της διακύμανσης και τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Training Time: 4.86 seconds
- Test MSE: 0.002632






Figure 11: Αναπαράσταση ψηφίων εισόδου και ανακατασκευής

Παρατηρούμε ότι η απόδοση της μεθόδου PCA κατατροπώνει παραδόξως τα περισσότερα νευρωνικά μοντέλα, παρά την απλότητά της. Το MSE κυμαίνεται στις τιμές του συνελκτικού μοντέλου, το οποίο ήταν έως τώρα το βέλτιστο, όμως ο χρόνος ανακατασκευής του PCA είναι συγκριτικά ασύλληπτος. Αυτό υποδηλώνει ότι η δομή των ψηφίων του MNIST είναι σε μεγάλο βαθμό γραμμικά διαχωρίσιμη και αναπαραστάσιμη, επιτρέποντας στο PCA να συλλάβει τα κύρια χαρακτηριστικά χωρίς την ανάγκη βαθιών μη-γραμμικών δικτύων.




Figure 12: Σύγκριση των μοντέλων αυτοκωδικοποίησης με βάση το MSE

## 2.7 CNN Classifier

Σαν τελευταίο βήμα γίνεται η υλοποίηση ενός κλασσικού συνελκτικού μοντέλου ταξινόμησης κλάσεων. Το μοντέλο εκπαιδεύεται στο αρχικό training set και εξετάζεται τόσο στο αρχικό test set όσο και σε κάποιο σετ ανακατασκευής από τα παραπάνω. Τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Accuracy on Original Test Images: 0.9910
- Accuracy on Reconstructed Images: 0.9895

Οι τιμές αυτές επιβεβαιώνουν την σχεδόν τέλεια ορθή ανακατασκευή των ψηφίων της MNIST.

### 3 Μέρος B: Autoencoder – Next Digit Reconstruction

Στο δεύτερο μέρος της εργασίας, το πρόβλημα αλλάζει ριζικά. Δεν ζητείται πλέον η απλή ανακατασκευή της εισόδου, αλλά η πρόβλεψη/κατασκευή του επόμενου ψηφίου. Πρόκειται για ένα πρόβλημα generative regression που είναι σημαντικά δυσκολότερο, καθώς δεν υπάρχει χωρική αντιστοιχία μεταξύ της εισόδου και της εξόδου.

Για τις ανάγκες του μέρους αυτού, απαιτήθηκε η αναδιάταξη του αρχικού συνόλου δεδομένων της MNIST. Δημιουργήθηκε ένα νέο dataset ζευγών εισόδου-εξόδου (επόμενου ψηφίου). Για την αποφυγή ανισορροπίας, το πλήθος των ζευγών για κάθε μετάβαση περιορίστηκε από το ελάχιστο πλήθος δειγμάτων των δύο εμπλεκόμενων κλάσεων. Ως αποτέλεσμα της διαδικασίας εξισορρόπησης, το τελικό dataset αποτελείται από **58.066** ζεύγη εκπαίδευσης και **9.674** ζεύγη ελέγχου.

Η υλοποίηση του μέρους B βρίσκεται στο αρχείο *Autoencoder\_B.ipynb*, ενώ οι βοηθητικές συναρτήσεις υλοποίησής του βρίσκονται στο *nextDigit.py*.

#### 3.1 Model 1: Dense Next Digit Autoencoder

Το πρώτο μοντέλο είναι ένα πλήρως συνδεδεμένο δίκτυο (Dense), παρόμοιο με αυτό του Μέρους A, αλλά με την προσθήκη Dropout layers για την αποφυγή overfitting, καθώς το task είναι πιο επιρρεπές σε αυτό. Γίνεται εκπαίδευση για 50 εποχές και τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Training Time: 214.11 seconds
- Final Validation Loss: 0.072078
- Test MSE: 0.060738




Figure 13: Καμπύλες σφάλματος training και validation




Figure 14: Αναπαράσταση ψηφίων εισόδου, επιθυμητής εξόδου και ανακατασκευής

Παρατηρούμε ότι το MSE είναι πολύ υψηλότερο σε σχέση με την απλή ανακατασκευή (που ήταν  $\sim 0.003$ ), κάτι αναμενόμενο αφού το δίκτυο προσπαθεί να μαντέψει τη μορφή του επόμενου ψηφίου χωρίς να έχει πληροφορία για το στυλ γραφής του. Η καμπύλη του validation loss δεν ακολουθεί καθόλου καλή πορεία, καθώς και οι εικόνες ανακατασκευής δεν είναι 100% ορθές.

### 3.2 Model 2: Convolutional Next Digit Autoencoder

Στο δεύτερο πείραμα, αντικαταστήθηκαν τα πλήρως συνδεδεμένα επίπεδα με ένα συνελικτικό δίκτυο, με στόχο να εξεταστεί αν η διατήρηση της χωρικής δομής της εισόδου βοηθάει στην πρόβλεψη του επόμενου ψηφίου. Εκπαιδεύουμε και πάλι για 50 εποχές αλλά με χρήση Early Stopping για την αποφυγή overfitting. Τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Training Time: 1395.70 seconds
- Stopped at Epoch: 15
- Final Validation Loss: 0.089768
- Test MSE: 0.065650




Figure 15: Καμπύλες σφάλματος training και validation




Figure 16: Αναπαράσταση ψηφίων εισόδου, επιθυμητής εξόδου και ανακατασκευής

Από την καμπύλη εκπαίδευσης παρατηρούμε ότι το μοντέλο κάνει έντονο overfitting από πολύ νωρίς. Το MSE δεν φαίνεται να παρουσιάζει βελτίωση, όπως και οι εικόνες ανακατασκευής που μοιάζουν ακόμη πιο θολές και όχι πλήρως ορθές.

### 3.3 Model 3: Advanced Convolutional Next Digit Autoencoder

Λαμβάνοντας υπόψιν το έντονο overfitting και την αδυναμία γενίκευσης, σε αυτό το στάδιο γίνονται δραστικές παρεμβάσεις. Γίνεται εισαγωγή των Dropout layers αναγκάζοντας το μοντέλο να «μάθει» πιο

ισχυρά χωρίς να απομνημονεύει τα δεδομένα εκπαίδευσης. Η συνάρτηση κόστους παύει να είναι το MSE και γίνεται το **BCE** (Binary-Cross Entropy), το οποίο αναγνωρίζει το μοντέλο ως ένα πρόβλημα πιθανοτικής ταξινόμησης. Δεδομένου ότι οι εικόνες του MNIST έχουν κανονικοποιηθεί στο  $[0, 1]$ , εξετάζεται πόσο πιθανό είναι το κάθε pixel να είναι "ενεργό". Επίσης γίνεται μείωση του Learning Rate ώστε η πιο αργή εκπαίδευση να επιτρέψει τη βαθύτερη σύγκλιση χωρίς ταλαντώσεις. Γίνεται πάλι εκπαίδευση για 50 εποχές με Early Stopping, αλλά για patience 10 αυτή τη φορά. Τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Training Time: 1925.83 seconds
- Stopped at Epoch: 18
- Final Validation Loss: 0.293896
- Test MSE: 0.060517




Figure 17: Καμπύλες σφάλματος training και validation




Figure 18: Αναπαράσταση ψηφίων εισόδου, επιθυμητής εξόδου και ανακατασκευής

Παρατηρούμε από την καμπύλη εκπαίδευσης ότι το μοντέλο ακολουθεί μια πιο σταθερή και ομαλή πορεία, παρουσιάζοντας ωστόσο στο τέλος πάλι ελαφρώς overfitting. Η αλλαγή σε BCE έκανε την εκπαίδευση πιο

ευαίσθητη στην ενεργοποίηση των pixels (μαύρο/άσπρο), αλλά οι τιμές σφάλματος παραμένουν ακόμη πολύ υψηλές. Αυτό υποδηλώνει ότι το μοντέλο παράγει εικόνες με αρκετή "αβεβαιότητα" (γκρίζες ζώνες) αντί για καθαρά ψηφία. Παρατηρείται επίσης εντονότερα η προσπάθεια προσέγγισης των ψηφίων 8,9,0 που επαναλαμβανομένων παρουσιάζουν σφάλμα.

### 3.4 Model 4: U-Net Style Next Digit Autoencoder

Στο τέταρτο πείραμα, υιοθετούμε την αρχιτεκτονική **U-Net**, η οποία αρχικά σχεδιάστηκε για βιοϊατρική κατάτμηση εικόνων, αλλά έχει αποδειχθεί εξαιρετικά ισχυρή σε προβλήματα image-to-image translation. Το δομικό στοιχείο που διαφοροποιεί το U-Net από τα κλασικά Autoencoders είναι τα **Skip Connections**. Σε έναν τυπικό Autoencoder η πληροφορία συμπιέζεται βίαια στο bottleneck, ενώ τα skip connections δημιουργούν «γέφυρες» μεταξύ Encoder και Decoder συνδέοντας τα αντίστοιχα συμμετρικά επίπεδα με συνένωση (Concatenation). Η χρήση U-Net στο συγκεκριμένο πρόβλημα είναι πειραματική καθώς τα skip connections είναι ιδανικά όταν η είσοδος και η έξοδος μοιάζουν δομικά, ενώ εδώ θέλουμε να αλλάξουμε το ψηφίο. Γίνεται εκπαίδευση για 50 εποχές και προστίθεται και Learning Rate Scheduler, οπότε τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Training Time: 3904.40 seconds
- Stopped at Epoch: 31
- Final Validation Loss: 0.304047
- Test MSE: 0.064115




Figure 19: Καμπύλες σφάλματος training και validation




Figure 20: Αναπαράσταση ψηφίων εισόδου, επιθυμητής εξόδου και ανακατασκευής

Η καμπύλη εκπαίδευσης υποδηλώνει μια αρκετά σταθερή πορεία και δείχνει ότι το Early Stopping λειτούργησε έγκαιρα αποτρέποντας το overfitting. Η τιμή του MSE για το test set ωστόσο δεν παρουσιάζει κάποια βελτίωση, ενώ οι εικόνες ανακατασκευής μοιάζουν περισσότερο «θολές» και «μπερδεμένες» παρά βελτιωμένες.




Figure 21: Σύγκριση των μοντέλων αυτοκωδικοποίησης με βάση το MSE

## 4 Μέρος Γ: Autoencoder – Digit Addition Reconstruction

Στο τρίτο και τελευταίο μέρος της εργασίας, το πρόβλημα καθίσταται ακόμη πιο σύνθετο, καθώς καλούμαστε να εκπαιδεύσουμε ένα Νευρωνικό Δίκτυο ώστε να εκτελεί την πράξη της πρόσθεσης,

χρησιμοποιώντας αποκλειστικά και μόνο οπτικές πληροφορίες (εικόνες) και όχι αριθμητικές τιμές. Στόχος είναι το δίκτυο να δέχεται ως είσοδο δύο εικόνες ψηφίων, να "κατανοεί" ποια ψηφία απεικονίζονται, να εκτελεί νοητά την πρόσθεση και να "ζωγραφίζει" το αποτέλεσμα. Για την υλοποίηση αυτού του task, δημιουργήθηκε ένα εξειδικευμένο dataset ζευγών, καθώς το MNIST από μόνο του περιέχει μεμονωμένα ψηφία. Για κάθε πιθανό ζεύγος ψηφίων επιλέχθηκαν τυχαίες εικόνες (28x28) από το dataset, δημιουργώντας μια νέα εικόνα εξόδου (28x56) η οποία αναπαριστά το άθροισμά τους. Για να αποφευχθούν προβλήματα μνήμης και ανισορροπίας, ορίστηκε ανώτατο όριο το 100 στον αριθμό των ζευγών για κάθε συνδυασμό πρόσθεσης.

Η υλοποίηση του μέρους Γ βρίσκεται στο αρχείο *Autoencoder\_C.ipynb*, ενώ οι βοηθητικές συναρτήσεις υλοποίησής του βρίσκονται στο *digitAdder.py*.

#### 4.1 Model 1: Dense Digit Adder Autoencoder

Ως σημείο αναφοράς, χρησιμοποιήθηκε ένα συμμετρικό πλήρως συνδεδεμένο δίκτυο (Dense Autoencoder). Το δίκτυο λαμβάνει ως είσοδο το ισοπεδωμένο διάνυσμα των δύο ψηφίων ( $28 \times 56 = 1568$ ) και καλείται να παράγει το διάνυσμα του αποτελέσματος. Επιλέγεται υψηλή χωρητικότητα δικτύου (μεγάλα layers) λόγω της δυσκολίας του προβλήματος. Γίνεται εκπαίδευση για 50 εποχές και τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Training Time: 88.11 seconds
- Final Validation Loss: 0.067438
- Test MSE: 0.066641




Figure 22: Καμπύλες σφάλματος training και validation






Figure 23: Αναπαράσταση ψηφίων εισόδου, επιθυμητής εξόδου και ανακατασκευής

Παρατηρείται έντονα overfitting από τη καμπύλη εκπαίδευσης, ενώ το MSE προμηνύει τη «θολούρα» των εικόνων. Ωστόσο τα ψηφία ανακατασκευής παρουσιάζουν ικανοποιητική ορθότητα.

## 4.2 Model 2: Deeper Dense Digit Adder Autoencoder

Προσπαθώντας να περιοριστεί το overfitting που εμφανίστηκε στο baseline μοντέλο, αυτή τη φορά αυξάνεται περισσότερο το βάθος του δικτύου και εισάγονται Dropout layers. Ο λανθάνων χώρος αυξάνεται σε 512 διαστάσεις για να χωρέσει την πολυπλοκότητα των δύο ψηφίων. Επίσης γίνεται μεταβολή του validation split σε 20% αντί για 40% δίνοντας την ευκαιρία στο μοντέλο να εκπαιδευτεί από ακόμη περισσότερα δεδομένα. Γίνεται εκπαίδευση για 50 εποχές με χρήση Early Stopping αυτή τη φορά και τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Training Time: 177.88 seconds
- Stopped at Epoch: 32
- Final Validation Loss: 0.060250
- Test MSE: 0.059476




Figure 24: Καμπύλες σφάλματος training και validation




Figure 25: Αναπαράσταση ψηφίων εισόδου, επιθυμητής εξόδου και ανακατασκευής

Παρατηρείται μια βελτίωση στη γενίκευση αφού η τιμή MSE παρουσιάζει μια ελαφριά μείωση, και η καμπύλη validation loss ακολουθεί σχεδόν σταθερά την καμπύλη training loss. Επομένως η χρήση Dropout layers είχε ευεργετική επίδραση. Οι εικόνες ανακατασκευής παρουσιάζουν λιγότερη «θολούρα».

### 4.3 Model 3: Convolutional Digit Adder Autoencoder

Στο τρίτο πείραμα, εγκαταλείπεται η πλήρως συνδεδεμένη αρχιτεκτονική και υιοθετείται και πάλι η συνελικτική, η οποία εξάγει τοπικά χαρακτηριστικά (όπως καμπύλες και γωνίες) από τα ψηφία εισόδου. Σε αντίθεση με τα συνελικτικά μοντέλα αναπαράστασης επόμενου ψηφίου, εδώ δεν χρησιμοποιούνται καθόλου ούτε στο εσωτερικό Dense layers, επομένως ο λανθάνων χώρος δεν είναι διάνυσμα, αλλά ένας τανυστής διαστάσεων (4, 7, 128). Αυτό σημαίνει ότι το δίκτυο κωδικοποιεί την πληροφορία της πρόσθεσης διατηρώντας τη σχετική θέση των χαρακτηριστικών. Ένα τεχνικό εμπόδιο στην αρχιτεκτονική αυτή είναι ότι το ύψος της εικόνας (28 pixels) δεν είναι δύναμη του 2, επομένως κατά την αποκωδικοποίηση χρησιμοποιείται το Cropping2D που επαναφέρει τις διαστάσεις στο σωστό μέγεθος. Επιλέγεται batch size = 128 για υπολογιστικούς σκοπούς και γίνεται εκπαίδευση για 50 εποχές με Early Stopping (patience = 10). Τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Training Time: 649.30 seconds
- Stopped at Epoch: 29
- Final Validation Loss: 0.065594
- Test MSE: 0.063397




Figure 26: Καμπύλες σφάλματος training και validation




Figure 27: Αναπαράσταση ψηφίων εισόδου, επιθυμητής εξόδου και ανακατασκευής

Από την καμπύλη εκπαίδευσης φαίνεται ότι το μοντέλο δυσκολεύτηκε πολύ στις πρώτες εποχές αλλά στην πορεία σταθεροποιήθηκε εντυπωσιακά, χωρίς σημάδια overfitting. Ωστόσο, παρατηρείται από την τιμή MSE ότι το συνελικτικό μοντέλο είχε παραδόξως χειρότερη απόδοση από το βελτιστοποιημένο Dense. Αυτό δείχνει ότι τα κλασικά CNNs δυσκολεύονται σε προβλήματα όπου η είσοδος και η έξοδος δεν έχουν άμεση χωρική αντιστοιχία. Ο ισχυρισμός αυτός επιβεβαιώνεται και από τις ανακατασκευασμένες εικόνες που παρουσιάζουν δραματικά σφάλματα.

### 4.3 Model 4: U-Net Style Digit Adder Autoencoder

Στο τέταρτο πείραμα, δοκιμάστηκε ξανά η αρχιτεκτονική U-Net με χρήση Skip Connections, υπό την υπόθεση ότι η μεταφορά πληροφορίας υψηλής ανάλυσης από τον encoder στον decoder θα βοηθούσε στην ευκρίνεια του αποτελέσματος. Επιπλέον, γίνεται προσθήκη Learning Rate Scheduler και εκπαίδευση ξανά για 50 εποχές με Early Stopping. Τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Training Time: 1204.55 seconds
- Stopped at Epoch: 29
- Final Validation Loss: 0.073589
- Test MSE: 0.073155




Figure 28: Καμπύλες σφάλματος training και validation




Figure 29: Αναπαράσταση ψηφίων εισόδου, επιθυμητής εξόδου και ανακατασκευής

Παρατηρείται ότι το U-Net πέτυχε το υψηλότερο σφάλμα από όλα τα μοντέλα που δοκιμάστηκαν. Αυτό είναι αντιφατικό με τη συνήθη συμπεριφορά του U-Net σε προβλήματα όρασης, αλλά και αναμενόμενο στο τρέχον πρόβλημα. Τα Skip Connections μεταφέρουν «ακατέργαστη» πληροφορία από την είσοδο απευθείας στην έξοδο, όμως η εικόνα του αθροίσματος δεν πρέπει να περιέχει κανένα ίχνος από την εικόνα των

προσθετέων. Το δίκτυο «μπερδεύεται» επειδή ο decoder λαμβάνει αντιφατικά σήματα, γεγονός που δημιουργεί θόρυβο στην τελική εικόνα, αυξάνοντας το MSE. Οι ανακατασκευασμένες εικόνες πράγματι μοιάζουν χειρότερες από κάθε άλλο μοντέλο.




Figure 30: Σύγκριση των μοντέλων αυτοκωδικοποίησης με βάση το MSE