

**Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών
Υπολογιστών**

Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης



Νευρωνικά Δίκτυα – Βαθιά Μάθηση
Εργασία 2

Τζίνα Θεοδώρα (ΑΕΜ: 10715)

Περιεχόμενα

1	Εισαγωγή	3
2	Μέρος Α: SVM – 2 classes	3
2.1	Linear Kernel	4
2.2	Polynomial Kernel	5
2.3	RBF Kernel	6
2.4	Sigmoid Kernel	8
3	Μέρος Β: SVM – 10 classes	8
4	Μέρος Γ: SVM - Optimization	9
4.1	HOG Features	10
4.2	Data Augmentation	11
4.3	Color Histogram Features	11
4.4	Τελική αξιολόγηση	12
5	Μέρος Δ: Comparison with other classifiers	13

1 Εισαγωγή

Στην παρούσα εργασία καλούμαστε να υλοποιήσουμε και να μελετήσουμε τη συμπεριφορά των Support Vector Machines (SVM), καθώς και να συγκρίνουμε την απόδοσή τους με εκείνη άλλων μεθόδων κατηγοριοποίησης όπως οι Nearest Neighbor, Nearest Class Centroid, MLP μονού κρυφού επιπέδου.

Όπως και στην προηγούμενη εργασία, χρησιμοποιήθηκε το dataset CIFAR-10. Ωστόσο, για τις ανάγκες της συγκεκριμένης άσκησης, το πρόβλημα μετατράπηκε από ταξινόμηση 10 κλάσεων σε δυαδικό πρόβλημα, ομαδοποιώντας τις κλάσεις σε δύο υπερ-κλάσεις: Ζώα (Animals) και Οχήματα (Vehicles). Η συγκεκριμένη μεθοδολογία ακολουθήθηκε διότι τα SVMs παρουσιάζουν βέλτιστη απόδοση και υπολογιστική αποδοτικότητα όταν καλούνται να διαχωρίσουν δεδομένα σε όσο το δυνατόν λιγότερες κλάσεις. Η μείωση του πλήθους των κλάσεων επιτρέπει στο μοντέλο να λειτουργήσει πιο αποδοτικά, αποφεύγοντας την αυξημένη πολυπλοκότητα που απαιτούν οι τεχνικές επέκτασης σε πολλαπλές κλάσεις (όπως One-vs-Rest ή One-vs-One).

Στόχος είναι η εύρεση του βέλτιστου μοντέλου SVM μέσω της δοκιμής διαφορετικών πυρήνων (kernels) και της βελτιστοποίησης των υπερπαραμέτρων τους (hyperparameter tuning).

2 Μέρος A: SVM – 2 classes

Όπως και στην προηγούμενη εργασία, γίνεται χρήση του dataset μέσω της βιβλιοθήκης Keras της Tensorflow.

1. Αρχικά γίνεται η φόρτωση του CIFAR-10 dataset, το οποίο αποτελείται από 50.000 εικόνες εκπαίδευσης και 10.000 εικόνες δοκιμής.
2. Οι παραπάνω ετικέτες μετατρέπονται σε δυαδικές μετασχηματίζοντας τις 10 κλάσεις σε 2 ως εξής:
 - Class 0 (Animals): Bird, Cat, Deer, Dog, Frog, Horse
 - Class 1 (Vehicles): Airplane, Automobile, Ship, Truck
3. Γίνεται εξ αρχής διαχωρισμός του συνόλου εκπαίδευσης σε training set (60%) και validation set (40%), προκύπτοντας 30.000 και 20.000 δείγματα αντίστοιχα. Σκοπός του διαχωρισμού αυτού είναι η διατήρηση του test set (10.000 δείγματα) αποκλειστικά για την τελική δοκιμή του βέλτιστου μοντέλου ώστε να προκύψουν όσο το δυνατόν γίνεται ρεαλιστικά αποτελέσματα.
4. Λόγω της ανισορροπίας των κλάσεων (περισσότερα ζώα από οχήματα), εφαρμόστηκε undersampling στην πλειοψηφούσα

- κλάση, οδηγώντας σε ένα ισορροπημένο σύνολο 24.000 δειγμάτων (12.000 ανά κλάση) για το training set.
5. Οι εικόνες ισοπεδώθηκαν (flatten) από διαστάσεις (32, 32, 3) σε διανύσματα διάστασης 3072 και κανονικοποιήθηκαν στο διάστημα [0, 1].
 6. Λόγω της αυξημένης χρονικής πολυπλοκότητας, γίνεται χρήση του Principal Component Analysis (PCA) για τη μείωση των διαστάσεων, διατηρώντας το 90% της διακύμανσης ως εξής:
 - Αρχική διάσταση: 3072 features
 - Τελική διάσταση: 99 features

Η προεπεξεργασία αυτή, βρίσκεται στο αρχείο *dataProcessing.py*.

Τα SVMs αυτής της εργασίας που θα ακολουθήσουν υλοποιήθηκαν με τη βοήθεια του πακέτου SVC της βιβλιοθήκης Scikit-Learn.

2.1 Linear Kernel

Ο Γραμμικός Πυρήνας (Linear Kernel) είναι ο πιο απλός και άμεσος, αφού προσπαθεί να διαχωρίσει τις δύο κλάσεις με ένα υπερεπίπεδο χωρίς να μεταβάλει καθόλου τα δεδομένα.

$$K(x, y) = x * y$$

Εξετάστηκε η υπερπαράμετρος ποινής 'C' στις τιμές [0.1, 1.0, 10.0]. Το C ελέγχει την ισορροπία μεταξύ της εύρεσης του ευρύτερου δυνατού περιθωρίου (margin) και της ελαχιστοποίησης των σφαλμάτων ταξινόμησης στα δεδομένα εκπαίδευσης. Τα αποτελέσματα που προέκυψαν είναι τα εξής:

- **Linear Kernel with C=0.1**
 - Training time: 452.63 seconds
 - Training Accuracy: 81.30%
 - Validation Accuracy: 80.84%
- **Linear Kernel with C=1.0**
 - Training time: 452.63 seconds
 - Training Accuracy: 81.30%
 - Validation Accuracy: 80.84%
- **Linear Kernel with C=10.0**
 - Training time: 3289.07 seconds
 - Training Accuracy: 81.31%
 - Validation Accuracy: 80.84%

Παρατηρούμε ότι το μοντέλο εμφάνισε σταθερή συμπεριφορά με accuracy περίπου στο 81%, το οποίο υποδηλώνει ότι τα δείγματα δεν είναι πλήρως γραμμικά διαχωρίσιμα και δεν μπορεί να υπάρξει βελτίωση.

Συμπέρασμα: Η επιλογή **C=0.1** ήταν η βέλτιστη γιατί πέτυχε τη μέγιστη δυνατή απόδοση για γραμμικό μοντέλο (81%) με το μικρότερο υπολογιστικό κόστος (λιγότερο χρόνο εκπαίδευσης).

2.2 Polynomial Kernel

Ο Πολυωνυμικός Πυρήνας (Polynomial Kernel) επιτρέπει στο SVM να αντιμετωπίζει δεδομένα που δεν μπορούν να διαχωριστούν με μια ευθεία γραμμή (μη γραμμικά διαχωρίσιμα). Χωρίς να χρειάζεται να υπολογίσει ρητά τις συντεταγμένες σε έναν τεράστιο χώρο διαστάσεων, προβάλλει τα δεδομένα σε χώρο υψηλότερων διαστάσεων.

$$K(x, y) = (x * y + c)^d$$

Εξετάστηκαν οι υπερπαράμετροι ποιότης 'C' και βαθμού 'degree' στις τιμές [0.1, 1.0, 10.0] και [2, 3, 5] αντίστοιχα. Η παράμετρος 'degree' καθορίζει πόσο "πολύπλοκη" και "λυγισμένη" μπορεί να είναι η καμπύλη διαχωρισμού των κλάσεων. Τα αποτελέσματα που προέκυψαν είναι τα εξής:

- **Polynomial Kernel with degree=2 (C=0.1)**
 - Training time: 25.36 seconds
 - Training Accuracy: 86.52%
 - Validation Accuracy: 85.60%
- **Polynomial Kernel with degree=3 (C=0.1)**
 - Training time: 23.06 seconds
 - Training Accuracy: 89.32%
 - Validation Accuracy: 86.98%
- **Polynomial Kernel with degree=5 (C=0.1)**
 - Training time: 56.20 seconds
 - Training Accuracy: 95.39%
 - Validation Accuracy: 87.72%
- **Polynomial Kernel with degree=2 (C=1.0)**
 - Training time: 25.90 seconds
 - Training Accuracy: 89.78%
 - Validation Accuracy: 87.36%
- **Polynomial Kernel with degree=3 (C=1.0)**
 - Training time: 54.71 seconds

- Training Accuracy: 94.26%
 - Validation Accuracy: 88.08%
- **Polynomial Kernel with degree=2 (C=10.0)**
- Training time: 91.54 seconds
 - Training Accuracy: 92.80%
 - Validation Accuracy: 87.50%
- **Polynomial Kernel with degree=3 (C=10.0)**
- Training time: 155.09 seconds
 - Training Accuracy: 98.67%
 - Validation Accuracy: 86.91%

Παρατηρούμε ότι το degree=5 απέτυχε και απορρίφθηκε εξ αρχής αφού οδήγησε σε μεγάλο κενό μεταξύ training και validation accuracy. Αντιθέτως οι βαθμοί 2 και 3 παρείχαν την απαραίτητη ευελιξία για τον διαχωρισμό των κλάσεων.

Συμπέρασμα: Όσο αυξάνεται το C, μικρότεροι βαθμοί πολυωνύμου (degree=2) αρκούν για καλή γενίκευση, ενώ αποφεύγεται το overfitting που παρατηρείται σε μεγαλύτερους βαθμούς.

2.3 RBF Kernel

Ο Πυρήνας Ακτινικής Βάσης (Radial Basis Function - RBF) είναι ο πιο δημοφιλής πυρήνας για μη γραμμικά προβλήματα. Αντί να προσπαθεί να τραβήξει γραμμές ή καμπύλες απευθείας, λειτουργεί με βάση την ομοιότητα, χρησιμοποιώντας συναρτήσεις Gauss («λόφους»).

$$K(x, y) = e^{-\text{gamma} * \|x - y\|^2}$$

Εξετάστηκαν οι υπερπαράμετροι ποινής 'C' και 'gamma' στις τιμές [0.1, 1.0, 10.0, 100.0] και [0.01, 0.001, 'scale'] αντίστοιχα. Η παράμετρος gamma καθορίζει πόσο "φαρδύς" ή "στενός" είναι ο «λόφος». Τα αποτελέσματα που προέκυψαν είναι τα εξής:

- **RBF Kernel with gamma=0.01 (C=0.1)**
- Training time: 36.32 seconds
 - Training Accuracy: 86.17%
 - Validation Accuracy: 83.97%
- **RBF Kernel with gamma=0.01 (C=1.0)**
- Training time: 54.71 seconds
 - Training Accuracy: 94.43%
 - Validation Accuracy: 87.67%

- **RBF Kernel with gamma=0.01 (C=10.0)**
 - Training time: 189.07 seconds
 - Training Accuracy: 99.62%
 - Validation Accuracy: 87.77%
- **RBF Kernel with gamma=0.001 (C=1.0)**
 - Training time: 27.93 seconds
 - Training Accuracy: 85.53%
 - Validation Accuracy: 84.62%
- **RBF Kernel with gamma=0.001 (C=10.0)**
 - Training time: 28.30 seconds
 - Training Accuracy: 89.41%
 - Validation Accuracy: 87.15%
- **RBF Kernel with gamma=0.001 (C=100.0)**
 - Training time: 109.02 seconds
 - Training Accuracy: 94.12%
 - Validation Accuracy: 88.37%
- **RBF Kernel with gamma='scale' (C=1.0)**
 - Training time: 86.32 seconds
 - Training Accuracy: 91.60%
 - Validation Accuracy: 87.33%
- **RBF Kernel with gamma='scale' (C=10.0)**
 - Training time: 1195.68 seconds
 - Training Accuracy: 98.20%
 - Validation Accuracy: 88.11%
- **RBF Kernel with gamma='scale' (C=100.0)**
 - Training time: 540.86 seconds
 - Training Accuracy: 99.92%
 - Validation Accuracy: 86.41%

Παρατηρούμε ότι για $\text{gamma}=0.001$ παρατηρείται καλύτερο accuracy – μικρότερο overfitting, από όταν $\text{gamma}=0.01$. Ωστόσο απαιτείται μεγαλύτερο C, γεγονός που ισχύει και για $\text{gamma}=\text{'scale'}$.

Συμπέρασμα: Στα πειράματα φάνηκε ότι όταν η "εμβέλεια" (gamma) είναι μικρή, χρειάζεται μεγαλύτερη "αυστηρότητα" (C) για να αντισταθμιστεί το όριο διαχωρισμού των κλάσεων.

2.4 Sigmoid Kernel

Ο Sigmoid Kernel προσομοιώνει τη λειτουργία ενός νευρωνικού δικτύου (tanh activation function).

$$K(x, y) = \tanh(ax^T y + c)$$

Αυτός ο τύπος είναι ακριβώς ο ίδιος με αυτόν που χρησιμοποιεί ένας νευρώνας σε ένα τεχνητό νευρωνικό δίκτυο (Perceptron) για να ενεργοποιηθεί. Η συνάρτηση tanh (υπερβολική εφαιπτομένη) μετατρέπει τις εισόδους σε τιμές μεταξύ -1 και 1. Τα αποτελέσματα που προέκυψαν είναι τα εξής:

- **Sigmoid Kernel with gamma='scale' (C=1.0)**
 - Training time: 61.23 seconds
 - Training Accuracy: 64.14%
 - Validation Accuracy: 63.79%
- **Sigmoid Kernel with gamma='scale' (C=10.0)**
 - Training time: 63.25 seconds
 - Training Accuracy: 64.08%
 - Validation Accuracy: 63.73%

Παρατηρούμε ότι ο Sigmoid Kernel είχε τη χειρότερη απόδοση από όλους, "κολλώντας" στο 64% accuracy, γεγονός που υποδεικνύει ότι ο αλγόριθμος μπορεί να παγιδεύεται σε τοπικά ελάχιστα ή να μην συγκλίνει καθόλου στη βέλτιστη λύση. Τα δεδομένα του CIFAR-10 (εικόνες που μετατράπηκαν μέσω PCA) τείνουν να ομαδοποιούνται με βάση την ομοιότητα (απόσταση). Ο Sigmoid, που βασίζεται σε γωνίες/ενεργοποιήσεις, δυσκολεύεται να βρει διαχωρισμό σε τέτοια δεδομένα.

Συμπέρασμα: Ο Sigmoid Kernel χρησιμοποιείται πλέον σπάνια στην επεξεργασία εικόνας, καθώς οι RBF πυρήνες και τα βαθιά νευρωνικά δίκτυα υπερτερούν συντριπτικά.

3 Μέρος B: SVM – 10 classes

Σε αυτή τη φάση της εργασίας εξετάστηκαν κάποια από τα καλύτερα μοντέλα που προέκυψαν από την προηγούμενη ενότητα της εργασίας (για classification των 2 κλάσεων), στο αυτούσιο CIFAR-10 dataset 10 κλάσεων. Σκοπός της δοκιμής αυτής είναι να αποδειχτεί ο ιοχυρισμός ότι τα SVMs δεν παρουσιάζουν την καλύτερη δυνατή απόδοση σε classification περισσότερων κλάσεων. Τα αποτελέσματα που προέκυψαν είναι τα εξής:

- **Linear Kernel SVM (C=1.0)**
 - Training time: 516.06 seconds
 - Training Accuracy: 42.27%
 - Validation Accuracy: 40.16%
- **Polynomial Kernel (C=1.0, degree=2)**
 - Training time: 190.84 seconds
 - Training Accuracy: 60.70%
 - Validation Accuracy: 50.60%
- **RBF Kernel SVM (C=1.0, gamma=0.01)**
 - Training time: 115.48 seconds
 - Training Accuracy: 76.03%
 - Validation Accuracy: 52.73%
- **Sigmoid Kernel SVM (C=1.0, gamma='scale')**
 - Training time: 123.20 seconds
 - Training Accuracy: 21.74%
 - Validation Accuracy: 21.32%

Παρατηρούμε ότι ο γραμμικός πυρήνας δυσκολεύτηκε σημαντικά να διαχωρίσει τις 10 κλάσεις και ήταν ο πιο αργός, ενώ ο πολυωνιμός μοιάζει καλύτερος μεν αλλά και πάλι όχι αρκετά ικανοποιητικός. Ο RBF πυρήνας πέτυχε και πάλι την υψηλότερη ακρίβεια στον μικρότερο χρόνο, αποδεικνύοντας την υπεροχή του σε μη γραμμικά δεδομένα. Ωστόσο, όπως και στο δυαδικό πρόβλημα, ο Sigmoid πυρήνας απέτυχε να μοντελοποιήσει τα δεδομένα.

Συμπέρασμα: Η μετάβαση από τις 2 στις 10 κλάσεις έριξε δραματικά την ακρίβεια (από ~88% σε ~53%). Αυτό υποδεικνύει ότι η χρήση απλών pixel features δεν επαρκεί για την πολυπλοκότητα του 10-class CIFAR-10 με SVMs.

4 Μέρος Γ: SVM - Optimization

Στο τρίτο μέρος της εργασίας, επιστρέφουμε στο δυαδικό πρόβλημα με στόχο την μεγιστοποίηση της απόδοσης μέσω βελτίωσης κάποιων από τα καλύτερα SVMs. Αντί για raw pixels, χρησιμοποιήθηκαν τεχνικές εξαγωγής χαρακτηριστικών (Feature Extraction) που περιγράφουν καλύτερα τη δομή των εικόνων.

4.1 HOG Features

Το Histogram of Oriented Gradients (HOG) είναι μια μέθοδος που περιγράφει το σχήμα και τις ακμές εντός της εικόνας, αγνοώντας σε μεγάλο βαθμό τον φωτισμό. Εξήχθησαν 324 HOG features ανά εικόνα. Τα δεδομένα εξισορροπήθηκαν (balancing) και κανονικοποιήθηκαν (StandardScaler). Η μέθοδος αυτή αντικατέστησε πλήρως τη μέθοδο PCA, η οποία αποτελούσε μια «τυφλή» στατιστική μέθοδο μαθηματικών συσχετίσεων. Το HOG σχεδιάστηκε ειδικά για την όραση υπολογιστών. Αντί να κοιτάζει σκέτα χρώματα (pixels), υπολογίζει κλίσεις και εντοπίζει ακμές και περιγράμματα.

Η υλοποίηση της μεθόδου αυτή βρίσκεται στο αρχείο *dataProcessing.py*.

Τα αποτελέσματα που προέκυψαν είναι τα εξής:

- **RBF Kernel using HOG (gamma=0.001, C=100.0)**
 - Training time: 758.91 seconds
 - Training Accuracy: 100.00%
 - Validation Accuracy: 88.83%
- **RBF Kernel using HOG (gamma='scale', C=1.0)**
 - Training time: 115.20 seconds
 - Training Accuracy: 95.88%
 - Validation Accuracy: 90.14%
- **RBF Kernel using HOG (gamma='scale', C=10.0)**
 - Training time: 461.31 seconds
 - Training Accuracy: 100.00%
 - Validation Accuracy: 90.34%

Παρατηρούμε ότι η μέθοδος HOG ανέβασε την ακρίβεια πάνω από το 90% για το καλύτερο έως τώρα μοντέλο με RBF Kernel. Η σταθερή παράμετρος gamma είχε την χειρότερη απόδοση και τον υψηλότερο χρόνο εκπαίδευσης, ενώ το gamma='scale', προσαρμόσε αυτόματα το εύρος του πυρήνα RBF στη διακύμανση των νέων χαρακτηριστικών HOG. Παράλληλα, η αύξηση του C σε 10.0 αναγκάζει το SVM να γίνει πιο "αυστηρό" και να προσπαθήσει να ταξινομήσει σωστά μερικά οριακά δείγματα (support vectors) που βρίσκονται κοντά στο όριο διαχωρισμού. Ωστόσο, το υπολογιστικό κόστος για αυτό το ελάχιστο κέρδος και την αυξημένη πιθανότητα εμφάνισης overfitting, είναι δυσανάλογο.

Συμπέρασμα: Η επιλογή C=1.0 προσφέρει την ιδανική ισορροπία ταχύτητας, απόδοσης και αξιοπιστίας.

4.2 Data Augmentation

Για την περαιτέρω ενίσχυση της ικανότητας γενίκευσης του μοντέλου, εφαρμόστηκε η τεχνική της Επαύξησης Δεδομένων (Data Augmentation). Συγκεκριμένα, χρησιμοποιήθηκε η μέθοδος της οριζόντιας αναστροφής (Horizontal Flipping) στο σύνολο εκπαίδευσης. Δημιουργώντας αντίγραφα «καθρέπτη» για κάθε εικόνα, διπλασιάστηκε τεχνητά το μέγεθος του training set από 24.000 σε 48.000 δείγματα. Στόχος ήταν να εκπαιδευτεί το SVM ώστε να αποκτήσει αμεταβλητότητα ως προς τον προσανατολισμό του αντικειμένου. Τα αποτελέσματα που προέκυψαν είναι τα εξής:

- **RBF Kernel using HOG + Augmentation (gamma='scale', C=10.0)**
 - Training time: 1729.99 seconds
 - Training Accuracy: 100.00%
 - Validation Accuracy: 90.75%

- **RBF Kernel using HOG + Augmentation (gamma='scale', C=1.0)**
 - Training time: 364.69 seconds
 - Training Accuracy: 95.67%
 - Validation Accuracy: 90.72%

Παρατηρούμε ότι για C=10.0 η προσθήκη του Data Augmentation παρά την μικρή αύξηση (+0.5%) απόδοσης, εκτόξευσε τον χρόνο εκπαίδευσης στο τετραπλάσιό του. Ωστόσο για C=1.0, ο χρόνος ναι μεν αυξήθηκε αλλά όχι σε τόσο δραματικό βαθμό, οδηγώντας σε απόδοση ύψους ~91% και διατηρώντας μια αποδεκτή απόσταση από το training accuracy.

Συμπέρασμα: Η χρήση Data Augmentation στα SVMs αποτελεί δίκοπο μαχαίρι. Η αύξηση της ακρίβειας κρίνεται θετική, αλλά το trade-off χρόνου είναι σημαντικό και πρέπει να λαμβάνεται υπόψιν.

4.3 Color Histogram Features

Στην προσπάθεια περαιτέρω βελτιστοποίησης, αναγνωρίστηκε ένας βασικός περιορισμός της μεθόδου HOG: η εστίασή του αποκλειστικά στις ακμές και το σχήμα. Ενώ αυτό είναι εξαιρετικό για την αναγνώριση της γεωμετρίας π.χ. ενός αυτοκινήτου, αγνοεί εντελώς τη χρωματική πληροφορία (π.χ. το καφέ ενός αλόγου ή το πράσινο ενός βατράχου). Για να καλυφθεί το κενό αυτό έγινε συνδυασμός των HOG features (342) με Color Histogram features. Υπολογίστηκαν ιστογράμματα χρώματος για κάθε εικόνα, χωρίζοντάς τες σε χρωματικά bins όπου καταμετρήθηκε η κατανομή των χρωμάτων (πόσο "κόκκινη", "πράσινη" ή "μπλε" είναι μια εικόνα). Επιλέχθηκαν 96 χαρακτηριστικά χρώματος, τα οποία

συνενώθηκαν με τα HOG χαρακτηριστικά σε ένα ενιαίο διάνυσμα μήκους 420.

Η υλοποίηση της μεθόδου αυτή βρίσκεται στο αρχείο *dataProcessing.py*.

Τα αποτελέσματα που προέκυψαν είναι τα εξής:

- **RBF Kernel using HOG + Augmentation + Color Histogram (gamma='scale', C=1.0)**
 - Training time: 532.73 seconds
 - Training Accuracy: 97.08%
 - Validation Accuracy: 92.28%

Παρατηρούμε σημαντική εκτόξευση ακρίβειας, καθώς το validation accuracy έφτασε το 92.28%. Πρόκειται για μια σημαντική αύξηση σε σχέση με το σκέτο HOG (~90.7%), αποδεικνύοντας ότι το χρώμα αποτελεί κρίσιμη διαχωριστική πληροφορία στο CIFAR-10.

Συμπέρασμα: Η στρατηγική του "Feature Fusion" αποδείχθηκε η πιο αποτελεσματική, καθώς συνδύασε τη γεωμετρική αυστηρότητα του HOG με την πλούσια πληροφορία του χρώματος, επιτυγχάνοντας τη μέγιστη διαχωριστική ικανότητα στο δυαδικό πρόβλημα.

4.4 Τελική αξιολόγηση

Με στόχο την επιβεβαίωση αποφυγής του φαινομένου overfitting και την οριστική επιλογή του υποψήφιου SVM ως το βέλτιστο μοντέλο για την τελική εφαρμογή στο test set, εξετάστηκε το πλήθος και το ποσοστό των support vectors. Τα αποτελέσματα που προέκυψαν είναι τα εξής:

- Total Support Vectors: 15037
- Training Samples: 48000
- Support Vectors Ratio: 31.33%

Παρατηρούμε ότι ο μικρός λόγος support vectors προς το σύνολο των δεδομένων υποδηλώνει ένα "σταθερό" μοντέλο με καλή ικανότητα γενίκευσης.

Τελικά γίνεται εφαρμογή του τελευταίου μοντέλου στο test set, το οποίο αποτελείται από 10.000 εικόνες και ως τώρα έχει διατηρηθεί ανέγγιχτο, διασφαλίζοντας έτσι την αντικειμενικότητα των αποτελεσμάτων. Τα αποτελέσματα που προκύπτουν είναι τα εξής:

- Test Accuracy: 92.59%

Class	Precision	Recall	F1-score	Support
Animal	0.95	0.93	0.94	6000
Vehicle	0.90	0.92	0.91	4000
Accuracy			0.93	10000
Macro Avg	0.92	0.93	0.92	10000
Weighted Avg	0.93	0.93	0.93	10000

Table 1: Classification Report




Figure 1: Confusion Matrix

Παρατηρούμε ότι η απόδοση στο test set είναι σχεδόν ταυτόσημη με αυτή του validation set, το οποίο αποτελεί ισχυρή ένδειξη ότι το μοντέλο γενικεύει εξαιρετικά, χωρίς να παρατηρείται φαινόμενο overfitting.

5 Μέρος Δ: Comparison with other classifiers

Στο τελευταίο μέρος, γίνεται σύγκριση του βέλτιστου SVM μοντέλου με άλλους ταξινομητές στο ίδιο δυαδικό πρόβλημα, χρησιμοποιώντας και τα ίδια features (HOG + Color Histogram). Ωστόσο, η διαδικασία του Data Augmentation παραλήφθηκε σε αυτή τη φάση για λόγους υπολογιστικού κόστους. Τα αποτελέσματα που προέκυψαν είναι τα εξής:

- **K-Nearest Neighbor (k=1)**
 - Training time: 0.73 seconds
 - Test set accuracy: 84.74%

- **K-Nearest Neighbor (k=3)**
 - Training time: 0.01 seconds
 - Test set accuracy: 87.38%
- **Nearest Class Centroid**
 - Training time: 0.25 seconds
 - Test set accuracy: 81.76%
- **MLP (1 hidden layer, Hinge Loss)**
 - Training time: 41.41 seconds
 - Test set accuracy: 90.20%

Σε όλα τα παραπάνω μοντέλα παρατηρείται ιδιαίτερα γρήγορη εκπαίδευση και αρκετά ικανοποιητικές αποδόσεις, χωρίς όμως κάποιο να ξεπερνάει το τελικό accuracy του βέλτιστου SVM.

Συμπέρασμα: Συγκριτικά με άλλες μεθόδους (kNN, NCC, MLP), το βελτιστοποιημένο SVM αναδείχθηκε ως ο ισχυρότερος ταξινομητής για το συγκεκριμένο δυαδικό πρόβλημα, αποδεικνύοντας ότι οι κλασικοί αλγόριθμοι μηχανικής μάθησης, όταν συνδυαστούν με σωστό feature extraction, μπορούν να γίνουν εξαιρετικά ανταγωνιστικοί.